

Etude Statistique sur les sauveteurs de Saint-Pierre-la-Mer

Mathis Pigassou

Avant propos

L'objectif principal de cette étude est de trouver un modèle statistique permettant d'expliquer au mieux le salaire des sauveteurs de Saint-Pierre-La-Mer entre le 15 juin 2025 et le 31 juillet 2025. La base de données créée pour cette étude contient $n = 44$ entrées provenant de 22 sauveteurs affectés au secteur de Saint-Pierre-la-Mer par le SDIS 11.




Figure 1: Nuage de points des 5 variables explicatives

1 Analyse

On pose la variable quantitative continue à expliquer Y : "Salaire". On pose les variables quantitatives discrètes explicatives candidates suivantes : X_1 : "Nombre de jours travaillés sur la quinzaine", X_2 : "Nombre d'heures travaillées sur la quinzaine", X_3 : "Nombre d'entraînements effectués sur la quinzaine", X_4 : "Nombre de réunions effectuées sur la quinzaine", X_5 : "Nombre de jours en plan d'eau sur la quinzaine".

1.2 Problématique

On cherche donc un modèle de la forme :

$$Y = \sum_{i \in I} \theta_i X_i + \beta + \epsilon$$

où les θ_i et β sont des paramètres à estimer et ϵ le terme d'erreur dans le modèle - pour lequel on pose l'hypothèse $\mathbb{E}[\epsilon] = 0$ et $\mathbb{V}[\epsilon] = \sigma^2 > 0$ où σ^2 est à estimer.

1.1 Choix du modèle

D'après 1, il semble y avoir une relation linéaire entre les variables explicatives et à expliquer. Dès lors, on cherche l'ensemble de variables $I \in \mathcal{P}([1;5])$, qui, parmi les 5 variables, explique le mieux Y d'après un modèle linéaire.

1.3 Critères de sélection

On choisit la minimisation de l' AIC , du BIC et du σ^2 comme critères d'optimisation du modèle. Le C de Mallows doit également être le plus proche du nombre de variables présentes dans le modèle. On fixe la probabilité de rejeter H_0 alors que H_0 est vrai à $\alpha = 0.05$.

1.4 Méthodologie

La méthode utilisée est descendante. Par conséquent, on part du modèle utilisant les 5 variables explicatives et on cherche, parmi les 5 variables, celle qui peut être supprimée en occasionnant la plus forte décroissance et cohérence des critères. Cette variable étant supprimée, on itère le processus. On arrête le processus lorsque les C de Mallows n'améliorent pas le C initial du modèle complet ou si l'un des critères à minimiser n'est pas amélioré sur l'ensemble des modèles.

1.5 Étude

Dans le modèle de régression où $I = \llbracket 1; 5 \rrbracket$, on a un $R^2 = 0,9875426$ (ajusté), un $AIC = 455,5741$, un $BIC = -668,3613$, un $\sigma^2 = 1463,8262$ et un $C = 4$.

Posons l'hypothèse de nullité $H_0 : \forall i \in I, \beta_i = 0$ et $H_1 : \exists i \in I : \beta_i \neq 0$. On a $F_{cal} = 299,3524$. Or, $F_{lim} = 2,0022 \times 10^{-29}$. Donc $F_{cal} \geq F_{lim}$. Donc d'après le test de Fisher-Snédecor on rejette H_0 et on conclut qu'il existe au moins un paramètre non nul dans le modèle. Posons l'hypothèse de nullité $H_0 : \beta_4 = 0$. On a, $T_{cal} = -0,2832$. Or, $T_{lim} = 0,7784$. Donc $|T_{cal}| < T_{lim}$. Donc d'après le test de Student, on ne peut pas rejeter H_0 . Cela signifie que, soit les données ne donnent pas assez de preuves pour dire que la variable X_4 a une influence non négligeable sur Y , soit H_0 est vraie.

Regardons maintenant les indicateurs pour $\text{card}(I) = 4$. Si $I = \{1, 2, 3, 5\}$, on a : $R^2 = 0,9875162$ (ajusté), un $AIC = 452,5240$, un $BIC = -444,5241$, un $\sigma^2 = 1429,3043$ et un $C = 2,08$. On peut donc conclure que la suppression d' X_4 dans le modèle complet n'entraîne pas son amélioration au sens du C de Mallows, du BIC et du AIC .

Si $I = \{1, 2, 4, 5\}$, on a : $R^2 = 0,9849296$ (ajusté), un $AIC = 460,7518$, un $BIC = -452,7518$, un $\sigma^2 = 1723,2001$ et un $C = 9,91$.

Si $I = \{1, 2, 3, 4\}$, on a : $R^2 = 0,98743072$ (ajusté), un $AIC = 452,8223$, un $BIC = -444,8223$, un $\sigma^2 = 1439,0255$ et un $C = 2,33$.

Si $I = \{2, 3, 4, 5\}$, on a : $R^2 = 0,97819653$ (ajusté), un $AIC = 476,8531$, un $BIC = -468,8532$, un $\sigma^2 = 2484,6260$ et un $C = 30,19$. Si $I = \{1, 3, 4, 5\}$, on a : $R^2 = 0,98725319$ (ajusté), un $AIC = 453,4355$, un $BIC = -445,4355$, un $\sigma^2 = 1459,2195$ et un $C = 2,87$. On peut remarquer que l'ensemble des R^2 ajustés des modèles à 4 variables diminue très faiblement par rapport au modèle complet, ce qui peut être causé par la suppression d'une variable - diminution mécanique. Toutefois, on peut également constater que les C de Mallows n'améliorent pas le modèle complet. En effet, aucun rapport entre le nombre de variables du modèle (ici 4) et la valeur du C de Mallows, ici $\frac{4}{C}$, n'est inférieur à 1,25, la valeur du ratio du modèle complet. Ceci est une condition suffisante pour stopper le processus de sélection - corroborée également par l'augmentation du BIC dans tous les modèles à 4 variables.

1.6 Validation du modèle

1.6.1 Contrôle de l'ajustement du modèle




Figure 2: Salaire observé en fonction du salaire prédit avec droite d'équation $y = x$

Le graphe 2 à 44 points (salaire observé, salaire prédit) est à peu près aligné selon la droite de pente 1 - courbe de régression : $y = x + 3 \times 10^{-12}$.




Figure 3: Résidus en fonction de la prévision du salaire

Le graphe 3 correspond à celui de deux variables non corrélées avec un $R^2 = -7 \times 10^{-16}$.

1.6.2 Colinéarités

La multi-colinéarité se produit lorsque les variables explicatives sont très corrélées entre elles. Cela conduit à des estimations biaisées des paramètres avec des variances importantes.

	X_1	X_3	X_5	X_2	X_4
X_1	1				
X_3	0,447	1			
X_5	0,187	0,129	1		
X_2	0,950	0,520	-0,059	1	
X_4	0,169	0,580	-0,073	0,295	1

Table 1: Matrice de corrélation entre les variables

D'après la Table 1 on remarque que le nombre d'heures travaillées sur une quinzaine est corrélé positivement avec le nombre de jours travaillés. Ce qui signifie que plus le nombre d'heures augmente, plus le nombre de jours augmente. Regardons maintenant le facteur d'inflation de la variance (VIF) et la tolérance ($1 - R^2$) de chaque variable. Pour X_1 , on a un $VIF = 84,27$ et une tolérance de 0,01. On a une tolérance qui tend vers 0 et un VIF qui tend vers $+\infty$, ce qui confirme un problème de multicollinéarité

entre les variables explicatives. Pour X_2 , on a également un problème de multi-colinéarité avec un $VIF = 91,83$ et une tolérance de 0,01.

Pour X_3 , on a un $VIF = 4,02$ et une tolérance de 0,24. Pour X_4 , on a un $VIF = 2,9$ et une tolérance de 0,34. Pour X_5 , on a un $VIF = 7,08$ et une tolérance de 0,14.

Conclusion

Nous pouvons donc conclure que le modèle de régression linéaire le plus explicatif d' Y est de la forme :

$$Y = \theta X + \beta + \epsilon$$

Avec X la matrice colonne des variables, $\theta = (66,9 \ 39,6 \ -9,2 \ -5,6 \ -3,2)$ la matrice ligne des coefficients, $\beta = -25,7$ une constante et où $\mathbb{V}[\epsilon] = 1463,8 > 0$

Annexe

Sur $n = 44$ entrées, 10 sont en dessous du SMIC horaire net établi en 2025, soit 9,4 € de l'heure [1].

References

- [1] Direction de l'information légale et administrative. *Smic (salaire minimum interprofessionnel de croissance)*. <https://www.service-public.fr/particuliers/vosdroits/F2300>. Consulté le 18 août 2025 - Vérifié le 13 juin 2025.